

Minería de datos

Diego Robles C

Presentación personal

Profesor investigador ITISB. Instituto de Tecnología para la Innovación en Salud y Bienestar. <https://itisb.cl/>

Kinesiólogo. Universidad Metropolitana de Ciencias de la Educación.

Magíster en Ciencias de la Ingeniería. Mención Ingeniería Biomédica. Universidad de Valparaíso.

Doctor en Ingeniería Informática Aplicada. Universidad de Valparaíso.

Correo institucional: diego.robles@unab.cl

Syllabus

Revisar documento publicado en Canvas.

Deber del estudiante revisarlo clase a clase y estudiar de la bibliografía obligatoria.

Unidades

Unidad I: El método científico en la ingeniería.

Unidad II: Preparación de la información.

Unidad III: Análisis utilizando aprendizaje automático supervisado.

Unidad IV: Análisis utilizando aprendizaje automático no supervisado.

Evaluaciones

NP=0.3 *Controles + 0.6 *Solemnes+ 0.1 Actividad complementaria

NF=0.7*NP+0.3*Examen.

Siendo necesario para la aprobación una nota igual o superior a 4.0

Se exige con nota mayor o igual a 5.0 y ninguna evaluación roja

Horarios

NRC 11785

Miercoles 14:00 -17:30


NRC 11783

Miércoles de 8:30-12:0

Bibliografía obligatoria

- **EMC Education Services** (2015). *"Data Science and Big Data analytics: Discovering, Analyzing, Visualizing and Presenting Data"*, 1st Edition.
- **Foster P. & Fawcett, T.** (2013). *"Data Science for Business: What you need to know about data mining and data-analytic thinking"*, 1st edition. O'Reilly Media.
- **Hernández, J., Ramírez, M. J., Ferri, C.** (2004). *"Introducción a la minería de datos"*. Pearson Educación, Madrid.
- **Hernández Sampieri, R., Fernández Collado, C., Baptista Lucio, P.** (2014). *"Metodología de la investigación"*, 6ta. Edición, Editorial McGraw Hill.

¿Qué entendemos por datos?



Juan Pérez obtuvo un 5.8 en la segunda prueba de historia

Juan Pérez obtuvo mejor nota que el 75% del resto del curso

Juan Pérez es un buen alumno

¿Qué entendemos por datos?

Colección de hechos tales como números, palabras, mediciones, o solo descripción de cosas.

Utilizado generalmente para análisis.

¿Cómo describimos los datos?



¿Qué significa Minar?

Extraer minerales

Limpiar lo extraído

Hacer grandes diligencias para extraer algo.



Un gran proceso

¿Qué es la minería de datos?

Descubrir **automáticamente** información **útil** en grandes repositorios de datos.

Orígenes de la MD

Los enfoques tradicionales fallaban con datos masivos.



¿Cuál es la diferencia entre Data Science, Machine Learning, e Inteligencia Artificial?

- **Data Science** es el nombre reciente para algo mucho más antiguo: **Data Mining (90's)**.
- Definición (sobre) simplista:
 - **Data mining** genera **entendimiento**.
 - **Machine learning** genera **predicciones**.
 - **Artificial intelligence** genera **acciones**.


¿Cuál es la diferencia entre Data Science, Machine Learning, e Inteligencia Artificial?


- **Artificial Intelligence:** auto reconoce una señal de STOP y toma la **acción** de frenar.
- **Machine Learning:** auto reconoce señales de STOP usando cámaras y **predice** en base a un entrenamiento cuando debe parar.
- **Data Mining:** auto transita por las calles y nos damos cuenta de que su rendimiento no es el esperado. Luego, **entendemos** que esto se debe a varios factores externos.

¿Por qué es importante entender estas diferencias?

- Porque este **no es un curso de Machine Learning, es un curso de Minería de Datos.**
- **ML: Estudio, diseño y desarrollo de algoritmos** que permiten a los computadores aprender sin ser explícitamente programados (Arthur Samuel). Técnicas genéricas, aplicables a varios dominios.
- **Minería de Datos:** El enfoque está en **extraer conocimiento**, o patrones previamente desconocidos, a partir de (grandes) volúmenes de datos (en su mayoría no estructurados). Para esto se pueden utilizar técnicas de ML, entre otras. Requiere conocimiento de los datos mismos y su dominio.

Descubrimiento de conocimiento en bases de datos (KDD)





¿Por qué hacer Minería de datos?

- **Aspecto comercial:**

Recomendaciones Personalizadas, Análisis de Comportamiento, Optimización de Ofertas, Prevención de Fraude, Investigación de Mercado, Mejora de la Experiencia del Cliente.

- **Aspecto científico.**

Datos (observaciones) recolectadas a gran velocidad (GB/hr, Tb/día)

¿Por qué hacer Minería de datos?

¿Motivación Científica?



Métodos y Técnicas

- **Métodos predictivos:** Usar variables para predecir variables desconocidas o valores futuros de otras variables.
- **Métodos descriptivos:** Encontrar patrones interpretables por humanos que permitan describir los datos.

Métodos utilizados en Minería de Datos

- **Clasificación (Predictivo)**
- **Clustering (Descriptivo)**
- **Descubrimiento de Reglas de Asociación (Descriptivo)**
- **Descubrimiento de Patrones Secuenciales (Descriptivo)**
- **Regresión (Predictivo)**
- **Detección de Desviación (Predictivo)**


Clasificación (Predictivo)

Set de Entrenamiento (atributos incluyendo clase)

Busca modelar en atributo clase


Objetivo: asignar la clase más correcta a records nuevos

Classification in Data Mining



Clasificación (Predictivo)

Nombre	Tipo sangre	Puede volar	Patas	Vive en el agua	Especie
Humano	Caliente	No	2	No	Mamífero
Rana	Fría	No	4	A veces	Anfibio
Paloma	Caliente	Si	2	No	Ave
Delfín	Caliente	No	0	Si	Mamífero



Entrenar
Clasificador




Modelo

Nombre	Tipo sangre	Puede volar	Patas	Vive en el agua	Especie
Tortuga	Fría	No	4	A veces	?
Búho	Caliente	Si	2	No	?




Clasificación (Predictivo)

Marketing directo: Reducir costos de publicidad apuntando directamente a potenciales compradores.




Clustering (Descriptivo)


- **Conjunto de puntos (datos)**, cada uno con un set de atributos y una medida de similitud.
- **Encontrar conjuntos tales que:**
 - Puntos en un *cluster* sean más similares entre sí.
 - Puntos en conjuntos diferentes sean menos similares entre sí.




Clustering (Descriptivo)



- Clustering 3D basado en distancia.
- Distancia intra-cluster es minimizada.
- Distancia inter-cluster es maximizada.



Segmentación de mercado



Meta: Subdividir un mercado en subconjuntos de clientes en donde cualquier conjunto es un potencial objetivo de marketing (ej: Netflix, Amazon, otras).

Descubrimiento de Reglas de Asociación (Descriptivo)

- **Dado un conjunto de records**, cada uno contiene un número de elementos de una colección determinada.
- **Objetivo:** Producir reglas de dependencia que predecirán la ocurrencia de un elemento (*ítem*) basándose en ocurrencias de otros ítems.

Descubrimiento de Reglas de Asociación (Descriptivo)

Market-Basket transactions

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke


Example of Association Rules

$\{\text{Diaper}\} \rightarrow \{\text{Beer}\},$
 $\{\text{Milk, Bread}\} \rightarrow \{\text{Eggs, Coke}\},$
 $\{\text{Beer, Bread}\} \rightarrow \{\text{Milk}\},$

Descubrimiento de Patrones Secuenciales (Descriptivo)


- **Dado un set de objetos** asociados a una línea de tiempo de eventos, encontrar los elementos que tengan fuertes dependencias secuenciales entre ellos.
- **Se forman reglas** descubriendo patrones y luego se aplican restricciones de tiempo.

Nobel de química 2024 por la predicción de la estructura de proteínas





David Baker (Washington, 1962), director del Institute for Protein Design de la Universidad de Washington, **Demis Hassabis** (Londres, 1976) y **John Michael Jumper** (Arkansas, 1985), cofundadores de la empresa **DeepMind**

El diseño de proteínas y sus múltiples usos




Regresión (Predictivo)

Predecir el valor de una variable continua, en base a valores de otras variables, asumiendo modelo de dependencia lineal o no-lineal.




Detección de Desviación (Predictivo)

Subject 232



Tipos de datos



Próxima sesión

1. Lectura y respuesta de preguntas. Reflexión de ética y Big data.
2. Introducción Google Colaboratory.