

Preprocesamiento de Datos

**Minería de datos
Diego Robles C**

Calidad de los datos

No poseen la calidad deseada a priori, los algoritmos de DM se enfocan en:

1. Detección y corrección de problemas de calidad
2. Usar algoritmos que toleren datos de poca calidad

i.e., limpieza de datos



¿Por qué se producen errores?

Tipos de errores:

- Ruido
- outliers
- Valores faltantes
- Datos duplicados
- Sesgo (Bias)

¿Qué es el ruido?

- Componente aleatorio en la medición.
- Datos espaciales, temporales.



Lena





Outliers

Objetos con características considerablemente diferentes a la mayoría.



Outliers



Preprocesamiento de datos

- Creación de atributos
- Selección de un subconjunto de atributos
- Agregación
- Normalización
- Muestreo
- Reducción de dimensionalidad
- Discretización y binarización
- Transformación

Agregación de datos


Combinar 2 o más atributos (o objetos) en un único atributo (o objeto)

¿Propósito?

- Reducción de datos
- Cambio de escala
- Datos más estables

Average Happiness for Twitter

All Tweets in English.




Muestreo


Principal técnica de selección de datos (investigación preliminar o final)

Usado en Estadística y DM


¿Cuándo es efectivo?

Muestreo aleatorio






Muestreo estratificado




Desbalance de las clases


Undersampling




Oversampling




Muestreo sistemático



Muestreo





8000 points



2000 Points





500 Points






Maldición de la dimensionalidad


- Al aumentar dimensionalidad, los datos se vuelven más dispersos en el espacio.
- Pierden significado las medidas, i.e. densidad y distancia entre puntos (clustering y detección de outliers)




```
(array([7, 3, 4, 1, 1, 3, 3, 9, 5, 7]),  
 array([4, 5, 4, 0, 8, 6, 2, 4, 8, 7]),  
 array([1, 3, 7, 5, 0, 1, 9, 3, 3, 0]))
```




$$10^1 = 10$$



$$10^2 = 100$$





$$10^3 = 1000$$




Reducción de la dimensionalidad

¿Propósito?

- Evitar *curse of dimensionality*
- Reducir costos asociados a aplicar el algoritmo (tiempo, memoria)
- Mejor visualización de los datos
- Ayuda a quitar atributos irrelevantes o ruidosos



De nuestra actividad de la semana anterior. Ética y big data



Reducción de la dimensionalidad y selección de atributos

Sirven para lo mismo:

- Selección de atributos.
- Reducción de dimensionalidad.

Selección de atributos

Fuerza bruta: trial and error muchas veces

Missing Values Ratio




Low Variance Filter





High Correlation Filter

<http://www.kdnuggets.com/2015/05/7-methods-data-dimensionality-reduction.html>

Escalar, Normalizar & Estandarizar

	ingreso	carros
0	22273.577534	3
1	8961.047249	1
2	7437.977263	2
3	12064.915290	2
4	9296.396167	1
...	...	...
995	9998.522402	0
996	6867.097603	2
997	9757.539280	1
998	11044.031510	1
999	1222.253800	0





Escalar en función del mínimo y máximo

```
array([[1.          , 1.          ],
       [0.36761553, 0.33333333],
       [0.29526521, 0.66666667],
       ...,
       [0.40545125, 0.33333333],
       [0.46656343, 0.33333333],
       [0.          , 0.          ]])
```

Normalizar en función de la Norma del Vector

```
array( [[0.06777903, 0.05886881],  
        [0.02726868, 0.01962294],  
        [0.02263394, 0.03924588],  
        ...,  
        [0.02969242, 0.01962294],  
        [0.03360725, 0.01962294],  
        [0.00371935, 0.          ]])
```


Estandarizar (desv_std = 1, media = 0)

```
(array([[ 4.81555174,  1.70892042],
        [-0.4413019 , -0.23193185],
        [-1.04273197,  0.73849429],
        ...,
        [-0.12678303, -0.23193185],
        [ 0.38122719, -0.23193185],
        [-3.49719763, -1.20235798]]),
array([[ 3.70548334,  1.          ],
        [-0.3376601 ,  0.          ],
        [-0.80023109,  0.5         ],
        ...,
        [-0.09575781,  0.          ],
        [ 0.29496225,  0.          ],
        [-2.68800607, -0.5         ]]))
```


Creación de atributos

- Extraer atributos
- Mapear atributos a un nuevo espacio
- Construir atributos (ejemplo bigrama de documento ética y big data)


Mapear a un nuevo espacio



• Two Sine Waves



Two Sine Waves +
Noise




Frequency

Discretizar


Decidir cuántas categorías tendremos

Supervisado (con clases, considerando entropía y pureza)


y no-supervisado (mismo intervalo, misma cantidad)




Data



Equal interval
width



Equal frequency



K-means

Algunos ejemplos en colab...