

Guía de estudio Análisis de Componentes Principales

Asignatura Minería de Datos

Diego Robles C

Introducción

La presente guía ha sido elaborada con el objetivo de **apoyar el proceso de aprendizaje autónomo** de los estudiantes en torno al uso y aplicación del **Análisis de Componentes Principales**, a un conjunto de datos reales provenientes de un sistema hidráulico industrial.

Dentro del set de actividades está el explorar la estructura interna de los datos, identificar relaciones entre variables, reducir la dimensionalidad y facilitar la interpretación de patrones mediante herramientas gráficas y analíticas.

La guía está diseñada para ser **complementaria a las clases teóricas**, promoviendo el desarrollo de habilidades prácticas en el uso de métodos estadísticos con herramientas computacionales, especialmente en entornos como Python y Google Colab. Se espera que el estudiante, al finalizar la actividad, sea capaz de interpretar resultados, evaluar la utilidad del PCA en contextos de ingeniería, y reflexionar sobre sus posibles aplicaciones en la industria.

Descripción:

Esta base de datos contiene **mediciones de sensores instalados en un sistema hidráulico industrial real**. Está orientado al mantenimiento predictivo, diagnóstico de fallos y monitoreo de condiciones operacionales.

- **2800 observaciones y 17 variables numéricas**, que incluyen:
 - Temperatura del aceite
 - Prensas hidráulicas
 - Caudal de aceite
 - Eficiencia del motor
 - Porcentaje de desgaste de componentes

Link base de datos:

<https://www.kaggle.com/jjacostupa/condition-monitoring-of-hydraulic-systems/data>

Preprocesamiento de los datos

- Cargar y explorar los datos.
- Eliminar variables categóricas si las hay, o convertirlas si es necesario (opcional).
- Verifique que todas las variables seleccionadas sean **numéricas y continuas**.
- Eliminar valores nulos.
- Escalar y normalizar los datos usando **StandardScaler**(media = 0, desviación estándar = 1).

3. Análisis exploratorio

- Calcular y graficar la **matriz de evaluación** entre todas las variables.
- Comentar si existen correlaciones altas entre algunas variables.

4. Aplicación de PCA

- Aplicar PCA sobre los datos estandarizados.
- Calcular y reportar:
 - **Valores propios** (eigenvalues).
 - **Vectores propios** (eigenvectors).
 - **Varianza explicada** por cada componente.
 - **Varianza acumulada** .
- Determinar cuántos componentes conservarías para explicar al menos un 70-80% de la variación.

5. Visualizaciones requeridas

- Gráfico de sedimentación (*scree plot*) con los valores propios.
- Gráfico de barras con la variación explicada por cada componente y la acumulada.
- **Círculo unitario no rotado** (utilizando los dos primeros componentes).
- **Círculo unitario rotado** (aplicar rotación Varimax si es posible).

- Tabla de **cargas factoriales** entre variables y componentes principales.

6. Interpretación

- Analizar la matriz de cargas factoriales (rotadas o no) e identificar:
 - ¿Qué variables están fuertemente asociadas a cada componente?
 - ¿Puedes interpretar el significado de los primeros componentes?
- Comenta si hay agrupaciones claras de variables o dimensiones latentes identificables.

7. Conclusiones

- Resume los hallazgos más relevantes del análisis.
- ¿Fue útil la reducción de dimensiones?
- ¿Qué aplicaciones prácticas podrían tener este tipo de análisis en el contexto de la base de datos?