

Unidad II: Preparación de la información

Minería de Datos

Diego Robles C

Contenidos

Causalidad vs. Correlación.


Coeficientes de correlación.

Modelo de regresión lineal simple.

Modelo de regresión lineal múltiple.

Causalidad vs. Correlación

Los países con mayor consumo de chocolate tienen más premios Nobel, por lo que recomiendan su consumo para mejorar la inteligencia [Maurage et al.2013].



"El consumo de chocolate mejora la función cognitiva" (New England Journal, 2012)

Variables de confusión



Correlación positiva entre los ataques de tiburones y las ventas de helados



Correlaciones espurias

<https://www.tylervigen.com/spurious-correlations>


Correlación

- Es una comparación o descripción de la asociación entre variables.
- Los cambios de alguna variable **Y** pueden ser explicados por los cambios de la otra **X**.
- Medida bivariada que mide la magnitud de la asociación entre dos variables y la dirección de dicha relación (-1 a 1), mientras que la regresión lineal genera un modelo.
- La visualización más común de datos bivariados es el diagrama de dispersión (*Scatterplot*), donde la coordenada **x** corresponde al valor de una variable y se coordinan con el valor de la otra variable.

Correlación

Las variables están correlacionadas positivamente, negativamente correlacionadas o no correlacionadas.

- Los valores de más grandes de una variable se asocian con los valores de más grandes de la otra.
- El aumento en una variable resulta en una disminución en la otra variable.



Coeficientes de correlación

Pearson: funciona bien para variables cuantitativas, método paramétrico, mide relación lineal, es sensible a valores extremos.

Rho de Spearman: se emplea principalmente para datos ordinales, de intervalo, cuantitativas que no satisfacen condición de normalidad, método no paramétrico, mide relación lineal y no lineal.

Tau de Kendall: método no paramétrico, se emplea cuando se dispone de pocos datos.

Coeficiente de correlación de Pearson: proporciona una medida de la relación lineal entre dos variables.

$$r = \frac{1}{n} \sum_{i=1}^n \frac{(x_i - \bar{x})(y_i - \bar{y})}{\sigma_x \sigma_y} \quad (1)$$

Donde:

x_i y y_i representan las observaciones o puntos de muestras individuales indexados por i ,

n es el tamaño de muestra,

$\bar{x}$ y $\bar{y}$ representan las medias,

y σ_x y σ_y son las desviaciones estándar de las variables x y y , respectivamente.

Persona	X (horas de estudio)	Y (nota del examen)
1	2	65
2	4	70
3	6	85

Calcular las medias ($\bar{x}$, $\bar{y}$):

$$\bar{x} = \frac{2 + 4 + 6}{3} = 4, \quad \bar{y} = \frac{65 + 70 + 85}{3} = 73.33$$

2. Calcular las desviaciones estándar:

$$\sigma_x = \sqrt{\frac{(2-4)^2 + (4-4)^2 + (6-4)^2}{3}} = \sqrt{\frac{4+0+4}{3}} = \sqrt{\frac{8}{3}} \approx 1.63$$

$$\sigma_y = \sqrt{\frac{(65-73.33)^2 + (70-73.33)^2 + (85-73.33)^2}{3}} = \sqrt{\frac{69.44 + 11.11 + 136.11}{3}} = \sqrt{72.22} \approx 8.49$$

3. Calcular el numerador:

$$(x_1 - \bar{x})(y_1 - \bar{y}) = (2 - 4)(65 - 73.33) = (-2)(-8.33) = 16.66$$

$$(x_2 - \bar{x})(y_2 - \bar{y}) = (0)(-3.33) = 0$$


$$(x_3 - \bar{x})(y_3 - \bar{y}) = (2)(11.67) = 23.34$$

$$\sum (x_i - \bar{x})(y_i - \bar{y}) = 16.66 + 0 + 23.34 = 40$$

Sustituimos en la fórmula:

$$r = \frac{1}{3} \cdot \frac{40}{1.63 \cdot 8.49} = \frac{40}{3 \cdot 13.84} = \frac{40}{41.52} \approx 0.96$$

Relación entre horas de estudio y nota del examen



Covarianza

El numerador en la ecuación (1) se conoce como la covarianza:

$$C_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) \quad (2)$$

Se utiliza a menudo como una estadística resumida de un diagrama de dispersión (*Scatterplot*).

Si la relación entre dos variables no es lineal, entonces se recomienda calcular un **coeficiente de correlación de rangos de Spearman**.

$$\rho_{\text{rank}} = \frac{C(R_X, R_Y)}{\sigma_{R_X} \sigma_{R_Y}} \quad (3)$$

donde, $C(R_X, R_Y)$ representa la covarianza del rango de las variables, y $\sigma_{R_X}, \sigma_{R_Y}$ las desviaciones de los rangos de las variables.

La (3) se reduce a la siguiente ecuación si todos los n rangos son distintos enteros,

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (4)$$

donde:

$$d_i = \text{rg}(X_i) - \text{rg}(Y_i)$$

Supongamos que tenemos datos de 5 estudiantes, con sus **puestos en dos pruebas diferentes**:

Estudiante	X (Puesto en Matemáticas)	Y (Puesto en Historia)
A	1	2
B	2	1
C	3	4
D	4	3
E	5	5

Diferencia de rangos y su cuadrado

Estudiante	X_i	Y_i	$d_i = X_i - Y_i$	d_i^2
A	1	2	-1	1
B	2	1	1	1
C	3	4	-1	1
D	4	3	1	1
E	5	5	0	0
Suma				4

Ecuación (4) de Spearman:

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

Donde:

- $\sum d_i^2 = 4$
- $n = 5$

$$r_s = 1 - \frac{6 \cdot 4}{5(5^2 - 1)} = 1 - \frac{24}{5 \cdot 24} = 1 - \frac{24}{120} = 1 - 0.2 = 0.8$$

Coeficiente de correlación

Kendall

$$\tau = \frac{2 \cdot S}{n(n-1)} \quad (5)$$

donde:

$$S = \sum (n_c - n_d)$$

n_c es el número de pares concordantes,

n_d representa el número de pares discordantes.

¿Qué es un par concordante?

Un par de observaciones (x_i, y_i) y (x_j, y_j) es **concordante** si:

- Cuando $x_i < x_j$, entonces $y_i < y_j$, o
- Cuando $x_i > x_j$, entonces $y_i > y_j$.

En otras palabras, ambas variables se mueven en la misma dirección.

¿Qué es un par discordante?

Un par es **discordante** si:

- Cuando $x_i < x_j$, entonces $y_i > y_j$, o viceversa.

Es decir, las variables se mueven en direcciones opuestas.

Supongamos que se evaluó a 4 personas en dos pruebas distintas:

Persona	X (Puesto en Prueba A)	Y (Puesto en Prueba B)
A	1	1
B	2	3
C	3	2
D	4	4

Se analizan todos los pares posibles (i, j) , con $i < j$:

1. (A, B): X: $1 < 2$, Y: $1 < 3 \rightarrow$ concordante
2. (A, C): X: $1 < 3$, Y: $1 < 2 \rightarrow$ concordante
3. (A, D): X: $1 < 4$, Y: $1 < 4 \rightarrow$ concordante
4. (B, C): X: $2 < 3$, Y: $3 > 2 \rightarrow$ discordante
5. (B, D): X: $2 < 4$, Y: $3 < 4 \rightarrow$ concordante
6. (C, D): X: $3 < 4$, Y: $2 < 4 \rightarrow$ concordante

Se analizan todos los pares posibles (i, j) , con $i < j$:

1. (A, B): X: $1 < 2$, Y: $1 < 3 \rightarrow$ concordante
2. (A, C): X: $1 < 3$, Y: $1 < 2 \rightarrow$ concordante
3. (A, D): X: $1 < 4$, Y: $1 < 4 \rightarrow$ concordante
4. (B, C): X: $2 < 3$, Y: $3 > 2 \rightarrow$ discordante
5. (B, D): X: $2 < 4$, Y: $3 < 4 \rightarrow$ concordante
6. (C, D): X: $3 < 4$, Y: $2 < 4 \rightarrow$ concordante

Total de pares: 6

Pares concordantes (n_c) = 5


Pares discordantes (n_d) = 1

$$S = n_c - n_d = 5 - 1 = 4$$

$$n = 4$$

$$\tau = \frac{2 \cdot S}{n(n-1)} = \frac{2 \cdot 4}{4 \cdot 3} = \frac{8}{12} = 0.67$$

Diagrama de dispersión de rangos - Tau de Kendall



Dadas dos variables Y y X , la significancia de la correlación se analiza mediante la:

Prueba t

- $H_0 : \rho = 0 \rightarrow$ las variables son independientes
- $H_1 : \rho \neq 0 \rightarrow$ existe relación entre las variables

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}, \quad df = n - 2 \quad (6)$$

Si el valor P -value $< 0,05$, entonces con un nivel de confianza del 95 % se concluye que la relación es estadísticamente significativa.

La cantidad de varianza de Y explicada por X se obtiene elevando al cuadrado el coeficiente de correlación r^2 , y se conoce como **coeficiente de determinación** R^2 .

Ejemplo

Supongamos que has calculado un **coeficiente de correlación de Pearson** entre las variables X (horas de estudio) y Y (nota del examen), y has obtenido:

$$r = 0,8, \quad n = 10$$

Queremos determinar si esta correlación es **estadísticamente significativa** al 95 % de confianza.

1. Hipótesis:

- $H_0 : \rho = 0$ (no hay correlación)
- $H_1 : \rho \neq 0$ (hay correlación)

2. Cálculo del estadístico t:

Usamos la fórmula:

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{0,8 \cdot \sqrt{10-2}}{\sqrt{1-0,8^2}} = \frac{0,8 \cdot \sqrt{8}}{\sqrt{1-0,64}} = \frac{0,8 \cdot 2,828}{\sqrt{0,36}} = \frac{2,262}{0,6} \approx 3,77$$

3. Grados de libertad:

$$df = n - 2 = 10 - 2 = 8$$

4. Valor crítico o p-valor:

Consultando una tabla t de Student (o usando software estadístico), con $df = 8$, un valor $t = 3,77$ da un **p-valor** $< 0,01$.

5. Conclusión:

Como $p < 0,05$, **rechazamos H_0** y concluimos que existe una correlación significativa entre las horas de estudio y las notas del examen.

6. Coeficiente de determinación:

$$R^2 = r^2 = 0,8^2 = 0,64$$

Esto significa que el **64 % de la variabilidad en las notas** se puede explicar por la cantidad de horas de estudio.

Interpretación del valor de correlación

Correlación	Interpretación
0.9 a 1.0 (−0.9 a −1.0)	Muy fuerte
0.7 a 0.9 (−0.7 a −0.9)	Fuerte
0.5 a 0.7 (−0.5 a −0.7)	Moderada
0.3 a 0.5 (−0.3 a −0.5)	Débil
0 a 0.3 (0 a −0.3)	Despreciable

Modelo de Regresión Lineal Simple

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i, \quad i = 1, 2, \dots, n \quad (10)$$

Donde:

- $\epsilon \sim \mathcal{N}(0, \sigma^2)$: el término de error sigue una distribución normal con media 0 y varianza constante σ^2 ,
- β_0 y β_1 son los **coeficientes de regresión**.

La variable aleatoria y tiene distribución con:


- **media condicional:**

$$E[y|x] = \beta_0 + \beta_1 x$$

- **varianza condicional:**

$$\text{Var}[y|x] = \sigma^2$$

Ejemplo de Regresión Lineal Simple



$$\hat{y} = 2.73 + 1.78x$$

Error Cuadrático Medio (ECM): 0.235

Coefficiente de Determinación $R^2 = 0.991$

Estimador de Mínimos Cuadrados Ordinarios (EMCO)

[Montgomery et al., 2006]

Estimación de β_0 y β_1

$$\min S(\beta_0, \beta_1) = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2 \quad (11)$$


Supuestos del EMCO

Existen 6 supuestos básicos sobre el EMCO [Rodríguez & González, 2017]


1. Linealidad
2. Rango Completo
3. Esperanza condicional de los errores nula
4. Perturbaciones esféricas
5. Variables explicativas no aleatorias
6. Normalidad de los errores

Ejemplo ideal: Cumplimiento de los supuestos del EMCO


1. Linealidad




2. Rango completo




3. $E[\text{error}|x] = 0$




4. Homocedasticidad




5. x sin error




6. Errores normales




1. Linealidad




2. Rango completo
(Colinealidad)




3. $E[\text{error}|x] \neq 0$




4. Heterocedasticidad



5. Variables x con error



6. Errores no normales




Modelo de regresión múltiple

- **Análisis de varianza.**
- **Coeficientes de determinación.**
- **Inferencia de los coeficientes.**

Regresión lineal **Múltiple**

Dos predictores (x_1 , x_2)



Variable de respuesta

Predictores

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

Intercepto

Parámetros (coeficientes) de regresión

Ejemplo

Con el fin de determinar la relación entre la calificación del desempeño laboral y y las calificaciones en cuatro exámenes (x_1) , (x_2) , (x_3) y (x_4) , el departamento de personal de cierta empresa industrial realizó un estudio en el que participaron 12 sujetos.

y	x_1	x_2	x_3	x_4
11.2	56.5	71.0	38.5	43.0
14.5	59.5	72.5	38.2	44.8
17.2	69.2	76.0	42.5	49.0
17.8	74.5	79.5	43.4	56.3
19.3	81.2	84.0	47.5	60.2
24.5	88.0	86.2	47.4	62.0
21.2	78.2	80.5	44.5	58.1
16.9	69.0	72.0	41.8	48.1
14.8	58.1	68.0	42.1	46.0
20.0	80.5	85.0	48.1	60.3
13.2	58.3	71.0	37.5	47.1
22.5	84.0	87.2	51.0	65.2

Modelo de regresión lineal múltiple

Dado el modelo con p variables independientes:

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + \varepsilon \quad (22)$$

con $\varepsilon \sim \mathcal{N}(0, \sigma^2)$

En forma matricial sería:

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{21} & \cdots & x_{p1} \\ 1 & x_{12} & x_{22} & \cdots & x_{p2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{pn} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix} \quad (23)$$

Donde el vector de parámetros β se obtiene:

$$\hat{\beta} = (X^T X)^{-1} X^T Y \quad (24)$$

Modelo de regresión lineal múltiple

$$Y = X\beta$$

$$\begin{pmatrix} 11.2 \\ 14.5 \\ 17.2 \\ \vdots \\ 22.5 \end{pmatrix} = \begin{pmatrix} 1 & 56.5 & 71 & 38.5 & 43 \\ 1 & 59.5 & 72.5 & 38.2 & 44.8 \\ 1 & 69.2 & 76 & 42.5 & 49 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & 84 & 87.2 & 51 & 65.2 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix}$$

Se puede estimar la variable de respuesta con el modelo:

$$\hat{Y}_i = 3.32 + 0.42X_1 - 0.3X_2 + 0.02X_3 + 0.12X_4$$

Supuestos sobre los residuales del modelo lineal

$$\varepsilon_i = y_i - \hat{y}_i$$

Residuales
(Error residual o aleatorio)

$$\hat{y}_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k$$

y estimada

$$y_i = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon_i$$

y observada

Residuales

Distribución normal

Varianza constante

Independencia


Violación de los supuestos sobre los
residuales



Transformación Box-Cox (potencia o
logaritmo natural de la variable
dependiente)

Validación del Supuesto de varianza constante de los Residuales



- La homocedasticidad implica que la varianza de los errores se mantiene constante a lo largo de los valores ajustados.
- Si este supuesto se viola, puede haber problemas con la eficiencia de los estimadores OLS.



Interpretación: **Banda homogénea:** no hay violación (caso ideal).

Tendencias crecientes/decrecientes o curvaturas: indican heterocedasticidad.

Validación del supuesto de distribución normal de los residuales



Prueba de **hipótesis** global (Significancia de la regresión)

¿Qué tan adecuado es el modelo
de regresión ajustado?

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

Regresión no significativa

$$H_1: \beta_i \neq 0 \text{ para al menos una } i = 1, 2, \dots, k$$

Regresión significativa

Regresión lineal Múltiple

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$$

Ejemplo

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	5	3.4899	0.6980	4.02	0.141
Residual Error	3	0.5205	0.1735		
Total	8	4.0104			

Criterio de rechazo con valor p

- $p < \alpha$: Rechazar H_0
- $p > \alpha$: No rechazar H_0
- $p = \alpha$: Incertidumbre

Pruebas de hipótesis

Coefficientes individuales de regresión

¿Cuáles variables son importantes o contribuyen al modelo de forma significativa?

Regresión lineal Múltiple $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$



$$\begin{array}{l} H_0: \beta_i = 0 \\ H_1: \beta_i \neq 0 \end{array} \xrightarrow{\text{green arrow}} \begin{array}{l} H_0: \beta_1 = 0 \\ H_1: \beta_1 \neq 0 \end{array} \quad \begin{array}{l} H_0: \beta_2 = 0 \\ H_1: \beta_2 \neq 0 \end{array} \quad \dots \quad \begin{array}{l} H_0: \beta_k = 0 \\ H_1: \beta_k \neq 0 \end{array}$$

Ejemplo

Predictor	Coef	SE Coef	T	P	VIF
Constant	0.6450	0.9856	0.65	0.534	
x1	0.001104	0.006847	0.16	0.876	6.0
x2	0.012147	0.007259	1.67	0.138	6.9
x3	-0.00030	0.02174	-0.01	0.989	7.1
x4	0.00692	0.01117	0.62	0.556	2.3
x5	0.003890	0.001958	1.99	0.087	2.2

Criterio de rechazo con valor p

- $p < \alpha$: Rechazar H_0
- $p > \alpha$: No rechazar H_0
- $p = \alpha$: Incertidumbre

Detección de la multicolinealidad

Matriz de correlación de las variable de regresión

Pearson correlation					
	x1	x2	x3	x4	x5
x2	0.329				
x3	0.251	-0.606			
x4	0.525	-0.007	0.515		
x5	-0.173	-0.627	0.771	0.118	
y	0.033	0.829	-0.820	-0.180	-0.776

Factor de inflación de la varianza (VIF)

$$VIF_i = \frac{1}{1 - R_i^2}$$

Predictor	Coef	SE Coef	T	P	VIF
Constant	0.6450	0.9856	0.65	0.534	
x1	0.001104	0.006847	0.16	0.876	6.0
x2	0.012147	0.007259	1.67	0.138	6.9
x3	-0.00030	0.02174	-0.01	0.989	7.1
x4	0.00692	0.01117	0.62	0.556	2.3
x5	0.003890	0.001958	1.99	0.087	2.2

$VIF_i = 1$ No multicolinealidad

$VIF_i > 1$ Multicolinealidad

$VIF_i > 5$ Multicolinealidad severa
(coeficientes de regresión pobremente estimados)