


Análisis utilizando aprendizaje automático

Minería de datos
Diego Robles C

How **Supervised** Machine Learning Works


STEP 1

Provide the machine learning algorithm categorized or "labeled" input and output data from to learn




STEP 2

Feed the machine new, unlabeled information to see if it tags new data appropriately. If not, continue refining the algorithm




TYPES OF PROBLEMS TO WHICH IT'S SUITED



CLASSIFICATION

Sorting items into categories




REGRESSION

Identifying real values (dollars, weight, etc.)

How **Unsupervised** Machine Learning Works


STEP 1

Provide the machine learning algorithm uncategorized, unlabeled input data to see what patterns it finds



STEP 2

Observe and learn from the patterns the machine identifies




TYPES OF PROBLEMS TO WHICH IT'S SUITED



CLUSTERING

Identifying similarities in groups

For Example: Are there patterns in the data to indicate certain patients will respond better to this treatment than others?



ANOMALY DETECTION

Identifying abnormalities in data

For Example: Is a hacker intruding in our network?

Recordar

- Un análisis de regresión, es un método para modelar la relación entre variables.
- Permite inferir o predecir una variable a partir de otra u otras.
- La variable que queremos predecir se denomina variable dependiente o criterio.
- Las variables que utilizamos para predecir se denominan independientes o predictoras


Supuestos para la regresión logística

- **Observaciones independientes:** no hay correlación entre las variables de entrada.
- **Variable dependiente binaria:** asume que la variable dependiente debe ser binaria o dicotómica, lo que significa que solo puede tomar dos valores.
- **Sin valores atípicos:** no debe haber valores atípicos en el conjunto de datos.
- **Gran tamaño de muestra:** El tamaño de la muestra es lo suficientemente grande.

Regresión lineal vs. regresión logística

En una regresión lineal, la variable dependiente es una variable métrica (salario, consumo de energía).

En una regresión logística, la variable dependiente es una variable dicotómica (compra un producto o no, enfermedad presente o no).




0=no enfermo


1= enfermo

Estimamos la probabilidad de que se produzca la clase 1

Linear Regression




Logistic Regression




Probabilidad

Grado de Certidumbre



$$p = \frac{\text{Casos favorables}}{\text{Casos totales}}$$

$$\text{ODDS} = \frac{P(\text{Éxito} \mid x_1)}{P(\text{Fracaso} \mid x_1)}$$



Partimos con la ecuación de los *log-odds*:

$$\ln(\text{odds}) = \ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 X$$

Esto describe la relación lineal entre los predictores (X) y el logaritmo del cociente de probabilidades (*odds*).

Aplicamos la función exponencial en ambos lados para deshacernos del logaritmo:

$$\frac{P}{1-P} = e^{\beta_0 + \beta_1 X} = e^{\beta X}$$

Aislamos P . Multiplicamos ambos lados por $1 - P$:

$$P = e^{\beta X}(1 - P)$$

Distribuimos el lado derecho:

$$P = e^{\beta X} - e^{\beta X} \cdot P$$

Llevamos todos los términos con P al mismo lado:

$$P + e^{\beta X} \cdot P = e^{\beta X}$$

Factorizamos P :

$$P(1 + e^{\beta X}) = e^{\beta X}$$

Despejamos P :

$$P = \frac{e^{\beta X}}{1 + e^{\beta X}}$$


Dividimos numerador y denominador por $e^{\beta X}$ (esto ayuda a simplificar la expresión y obtener la forma estándar):

$$P = \frac{1}{1 + e^{-\beta X}}$$

$$P = \frac{1}{1 + e^{-\beta_0 - \beta_1 X}}$$


Regresión Lineal

Proporciona una salida continua
Conocer el porcentaje de probabilidad
de lluvia o el precio de una acción



Regresión Logística

Proporciona una salida discreta
Conocer si va a llover o no,
o si el precio de una acción subirá o no



Para estimar un modelo LOGIT se deben tener en cuenta:

1. Los parámetros se estiman mediante el método de máxima verosimilitud y no por el de MCO, porque la ecuación no es lineal.
2. Para la significancia de los parámetros o coeficientes del modelo se utiliza la distribución normal asintótica y no la *t – student*. Se utiliza **Z-scores**
3. El coeficiente de determinación R^2 no es útil, en su lugar se utilizan pseudo R^2
4. Los parámetros deben tener signos lógicos en la estimación.
5. Estos modelos toman forma de función de distribución acumulada (CDF) a lo largo de la suma de todas las probabilidades.

Estimación de Verosimilitud

$$L(\beta) = \prod_{i=1}^n p_i^{Y_i} (1 - p_i)^{1-Y_i}$$

Log-Verosimilitud

$$\ell(\beta) = \log(L(\beta)) = \sum_{i=1}^n [Y_i \log(p_i) + (1 - Y_i) \log(1 - p_i)]$$

$$L(\beta) = \prod_{i=1}^n p_i^{Y_i} (1 - p_i)^{1-Y_i}$$

¿Qué significa?

- p_i : probabilidad predicha por el modelo de que el individuo i pertenezca a la clase 1.
- Y_i : valor real observado (0 o 1).
- Si $Y_i = 1$, la contribución es p_i ; si $Y_i = 0$, la contribución es $1 - p_i$.


Ejemplo (caso binario):

Persona	Sobrevivió (Y_i)	Probabilidad p_i (modelo)	Contribución a la verosimilitud
A	1	0.9	$0.9^1 = 0.9$
B	0	0.3	$(1 - 0.3)^1 = 0.7$
C	1	0.8	$0.8^1 = 0.8$

$$L(\beta) = 0.9 \cdot 0.7 \cdot 0.8 = 0.504$$

$$\ell(\beta) = \log(L(\beta)) = \sum_{i=1}^n [Y_i \log(p_i) + (1 - Y_i) \log(1 - p_i)]$$


$$\ell(\beta) = \log(0.9) + \log(0.7) + \log(0.8) \approx -0.105 + (-0.357) + (-0.223) = -0.685$$



Medida de qué tan bien el modelo predice los datos observados


Máxima Verosimilitud

TAQUICARDIA



NORMAL

Frontera de decisión



Matriz de confusión

VALORES PREDICCIÓN	VALORES REALES	
	Positivo	Negativo
Positivo	Verdaderos positivos	Falsos Positivos
Negativo	Falsos Negativos	Verdaderos Negativos

- **Verdadero positivo:** El valor real es positivo y la prueba predijo también que era positivo. O bien una persona está enferma y la prueba así lo demuestra.
- **Verdadero negativo:** El valor real es negativo y la prueba predijo también que el resultado era negativo. O bien la persona no está enferma y la prueba así lo demuestra.
- **Falso negativo:** El valor real es positivo, y la prueba predijo que el resultado es negativo. La persona está enferma, pero la prueba dice de manera incorrecta que no lo está. Esto es lo que en estadística se conoce como **error tipo II**
- **Falso positivo:** El valor real es negativo, y la prueba predijo que el resultado es positivo. La persona no está enferma, pero la prueba nos dice de manera incorrecta que si lo está. Esto es lo que en estadística se conoce como **error tipo I**

Type I error
(false positive)



Type II error
(false negative)



Exactitud (Accuracy)

- **Pregunta que responde:**

¿Qué proporción del total de predicciones fueron correctas?

- **Definición:**

Es la proporción de casos correctamente clasificados (positivos y negativos) sobre el total de casos evaluados.

- **Fórmula:**

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Precisión Positiva (Precision)

- **Pregunta que responde:**

De todas las veces que el modelo predijo "positivo", ¿cuántas veces acertó realmente?

- **Definición:**

Mide la exactitud de las predicciones positivas. Es útil cuando el costo de un falso positivo es alto.

- **Fórmula:**

$$\text{Precision} = \frac{TP}{TP + FP}$$

Sensibilidad / Exhaustividad (Recall o Sensitivity)

- **Pregunta que responde:**

De todos los casos realmente positivos, ¿cuántos fueron identificados correctamente por el modelo?

- **Definición:**

Evalúa la capacidad del modelo para detectar correctamente los casos positivos. Es crucial cuando el costo de un falso negativo es alto (por ejemplo, en diagnóstico médico).

- **Fórmula:**

$$\text{Recall} = \frac{TP}{TP + FN}$$

F1-Score

- **Pregunta que responde:**

¿Cuál es el equilibrio entre la precisión y la sensibilidad?


- **Definición:**

Es la media armónica entre precisión y recall. Se usa cuando se quiere balancear ambas métricas, especialmente en datasets desbalanceados.

- **Fórmula:**

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Curva ROC (Receiver Operating Characteristic)



Exactitud y precisión

