

Unidad III. Análisis utilizando aprendizaje supervisado **Árboles de decisión**


Diego Robles Cruz

Minería de Datos

Árboles de decisión

"Un árbol de decisión es un modelo predictivo que utiliza un conjunto de reglas basadas en las características de los datos para tomar decisiones o hacer predicciones."

"El objetivo de los árboles de decisión es dividir un conjunto de datos en subconjuntos más homogéneos, usando reglas derivadas de las características más significativas."




¿Para qué sirven?

- **Clasificación:** Se utilizan para clasificar elementos dentro de diferentes categorías o clases.
- **Regresión:** También pueden ser usados para predecir valores continuos, como precios o temperaturas.
- **Análisis de decisiones:** Ayudan a visualizar y estructurar decisiones secuenciales, lo que facilita la toma de decisiones en situaciones complejas.

¿Cómo funciona?

- **Raíz:** El punto de partida que representa todo el conjunto de datos.
- **Nodos:** Cada nodo intermedio representa una característica y su valor umbral.
- **Hojas:** Las hojas contienen la predicción final, ya sea una clase o un valor.



Criterios de división

- **Gini Impurity:** Una medida de la impureza o desorden dentro de los datos. Se busca minimizar esta métrica.
- **Entropía (ID3):** Una medida de la cantidad de desorden, utilizada para elegir la mejor división.
- **MSE (Mean Squared Error):** Para problemas de regresión, se utiliza el error cuadrático medio para encontrar la mejor partición.

Construcción

- **Seleccionar la Mejor Característica:** La característica que más divide el conjunto de datos se selecciona para ser el nodo raíz.
- **Dividir los Datos:** Los datos se dividen en subconjuntos según los valores de la característica seleccionada.
- **Repetir el Proceso:** Se repite el proceso para cada subconjunto, creando nodos secundarios hasta llegar a un criterio de parada.

Algunos usos comunes son:

- Detección de **fraude**.
- **Medicina**: Predicción de enfermedades.
- **Marketing**: Segmentación de Clientes.

Ventajas

- **Simplicidad y Claridad:** Fáciles de entender y visualizar.
- **No requiere preprocesamiento:** No siempre necesitan escalado ni normalización de los datos.
- **Manejo de datos categóricos y numéricos:** Pueden manejar ambos tipos de datos sin problemas.
- **Interactividad:** Permiten seguir fácilmente el camino de decisión.

Desventajas

- **Sobreajuste:** Pueden volverse demasiado complejos.
- **Inestabilidad:** Pequeñas variaciones en los datos pueden producir un árbol completamente diferente.
- **Predicciones lineales:** Las predicciones en los bordes pueden ser menos precisas.

Índice Gini

$$\text{Gini} = 1 - \sum_{i=1}^C p_i^2$$


donde:

- C es el número de clases,
- p_i es la proporción de ejemplos de la clase i en el nodo actual.

Interpretación

- El **índice de Gini** mide la **impureza** de un nodo.
- Un valor de **0** indica que todos los ejemplos del nodo pertenecen a **una sola clase** (nodo puro).
- Un valor cercano a **1** indica una distribución equilibrada entre varias clases (alta impureza).
- El algoritmo del árbol de decisión busca **minimizar** este valor al dividir los datos.

Ejemplo




Umbrales


Supongamos que el árbol genera esta partición:

1. **Primer corte** en $x_0 = 5.5$ (fuerza)

- Si $x_0 \leq 5.5$: izquierda (rojos)
- Si $x_0 > 5.5$: derecha

2. Luego en la derecha se hace un corte en $x_1 = 6.5$ (letalidad)





● **Nodo raíz: (todos los datos)**

- Total: 20 muestras
- 10 rojas, 10 verdes

$$Gini_{raiz} = 1 - (10/20)^2 - (10/20)^2 = 1 - 0.25 - 0.25 = 0.5$$

■ **Rama izquierda: $x_0 \leq 5.5$**

- Total: 10 muestras
- Todas son **rojas**

$$Gini_{izquierda} = 1 - (10/10)^2 - (0/10)^2 = 1 - 1 - 0 = 0$$

■ **Nodo derecho: $x_0 > 5.5$**

- Total: 10 muestras
- Todas son **verdes**

$$Gini_{derecha} = 1 - (0/10)^2 - (10/10)^2 = 1 - 0 - 1 = 0$$

■ **División opcional en el nodo derecho: $x_1 \leq 6.5$**

■ **Hoja inferior (letalidad baja)**

- 5 verdes, 0 rojas → Gini = 0

■ **Hoja superior (letalidad alta)**

- 5 verdes, 0 rojas → Gini = 0

Como ves, las **dos hojas verdes** del nodo derecho **siguen siendo puras**, por eso esa división **no es necesaria**.

Entropía


La entropía es una medida de aleatoriedad en un sistema. Para una distribución de probabilidad con k clases, se define como:

$$Entropy = \sum_k -p_k \log_2 p_k$$

donde p_k es la probabilidad de que un artículo pertenezca a la k -ésima clase.

La función de entropía para una variable aleatoria binaria x :

- Alcanza su valor **máximo de 1** cuando la probabilidad es 0.5; es decir, hay una **probabilidad del 50-50** de que $x = 1$ o $x = 0$.
- La función alcanza un **mínimo en 0** cuando $p(x = 1) = 1$ o $p(x = 1) = 0$.
En otras palabras, cuando tenemos **total certeza**.



Curva de entropía